Predicción de abandono de clientes para campañas de retención

Sergio Perez (202314506) y Samuel Charry (202313509)
MINE-4101 Ciencia de Datos Aplicada · Universidad de los Andes · 2026-20
Repositorio: github.com/53R6IO/Taller2CDA

Índice

1. Contexto y objetivo 1
2. Hallazgos principales 1
3. Resultados del modelo 2
4. Valor para el banco 3
5. Recomendación 4
Declaración de uso de IA generativa 4
Referencias 4

1. Contexto y objetivo

Contexto. FinAlpes quiere ofrecer a los bancos una herramienta que detecte a tiempo a los clientes en riesgo de abandono, para enfocar las campañas de retención. La prueba de concepto usa 10.000 clientes europeos y se adapta a un banco colombiano de 20.000 clientes con 15 % de abandono anual. La campaña convence al 30 % de los clientes que se iban a ir, pero se paga por cada cliente contactado (Universidad de los Andes, 2026).

Objetivo. Decidir a qué clientes contactar para que la campaña deje más de lo que cuesta.

2. Hallazgos principales

Quién abandona. El 20,4 % de los clientes del dataset abandona. El riesgo depende sobre todo de cuatro rasgos (Figuras 1 y 2):

- **Edad:** el riesgo sube de golpe entre los 40 y los 50 años.
- **Número de productos:** con 2 productos abandona ~8 %; con 1, ~28 %; con 3 o 4, casi todos.
- **Actividad:** los inactivos abandonan ~27 % y los activos ~14 %. En los inactivos la edad pesa todavía más.
- **País:** en Alemania abandona ~32 %, el doble que en Francia y España.

El balance, el género y el puntaje de crédito pesan menos en el modelo. El salario, la antigüedad y tener tarjeta de crédito no se relacionan con el abandono.

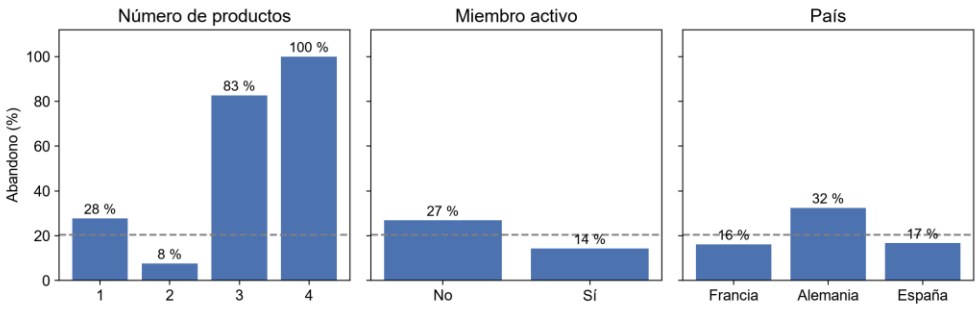


Figura 1. Tasa de abandono por grupo. La línea punteada es la tasa global (20,4 %).

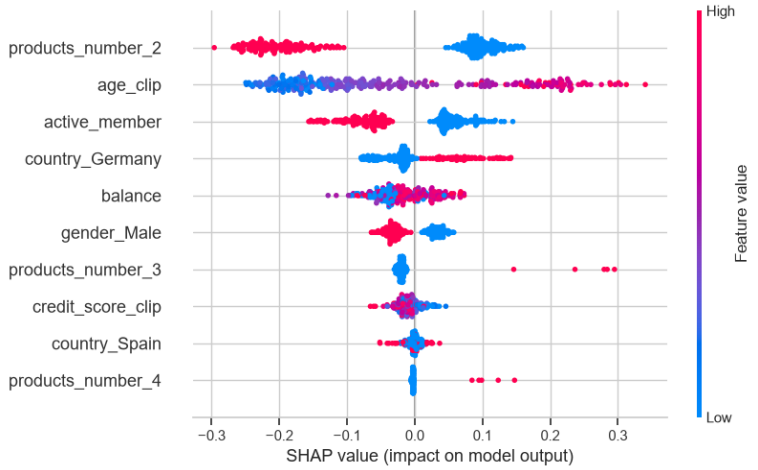


Figura 2. Valores SHAP de Random Forest en 300 clientes de prueba. A la derecha la variable sube el riesgo; rojo es un valor alto.

3. Resultados del modelo

Modelos. Se probaron ocho modelos siguiendo las prácticas del curso (Universidad de los Andes, s. f.) y quedaron dos finalistas: una regresión logística, la más simple, y un Random Forest, los dos con class_weight = "balanced" para no ignorar a los clientes que abandonan. Se eligió Random Forest por tener el mayor F1 en validación (0,584 frente a 0,551), y en prueba se mantiene (Tabla 1).

Métrica	Random Forest	Regresión logística
Exactitud	0,807	0,764
Precisión	0,519	0,453
Recall	0,705	0,762
F1	0,598	0,568
AUC	0,85	0,83
AP	0,68	0,61

Tabla 1. Métricas en el conjunto de prueba (2.000 clientes, umbral 0,5).

Significancia. La ventaja en F1 es real: la diferencia es de 0,030 y su intervalo de confianza del 95 % va de 0,005 a 0,055 (bootstrapping pareado, p = 0,014). Random

Forest da menos falsas alarmas (266 frente a 374), pero la logística detecta más abandonos (McNemar sobre los que abandonan, p = 0,002).

Errores. El modelo detecta 7 de cada 10 clientes que se van. En el caso revisado, el cliente que se le escapó tenía el perfil de quien se queda (activo y con 2 productos): se fue por razones que no están en los datos. Un modelo que siempre diga "no abandona" tendría 79,6 % de exactitud sin detectar a nadie; por eso se evalúa con recall, precisión y F1.

4. Valor para el banco

Supuestos. Un cliente retenido vale 700.000 pesos al año (punto medio del enunciado). Cada contacto cuesta 45.230 pesos: una llamada de USD 1 (Talkyria, 2026), a 3.230 pesos por dólar (Dólar Colombia, 2026), y tres meses sin cuota de manejo de 14.000 pesos (Noticias RCN, 2026). La inversión es de 160,4 millones de pesos: equipo por tres meses con salarios de mercado (Indeed, 2026; Glassdoor, 2026; Elempleo, 2026; UNIR, s. f.), nube, integración con el CRM, capacitación y 10 % de contingencia. La precisión se ajusta al 15 % de abandono del banco.

Ganancia. Con la matriz costo-beneficio (Provost y Fawcett, 2013), cada abandono detectado deja 164.770 pesos (30 % de 700.000 menos el contacto) y cada falsa alarma cuesta 45.230. El modelo no pierde plata mientras su precisión supere 0,215. Con umbral 0,5, Random Forest deja 11.009 pesos al año por cliente evaluado, unos 18,3 millones al mes, y recupera la inversión en 8,7 meses (Figura 3). Con umbral 0,6, el que más gana en validación, sube a unos 20 millones al mes, se recupera en 8 meses y su ROI a 12 meses es de 49 %.

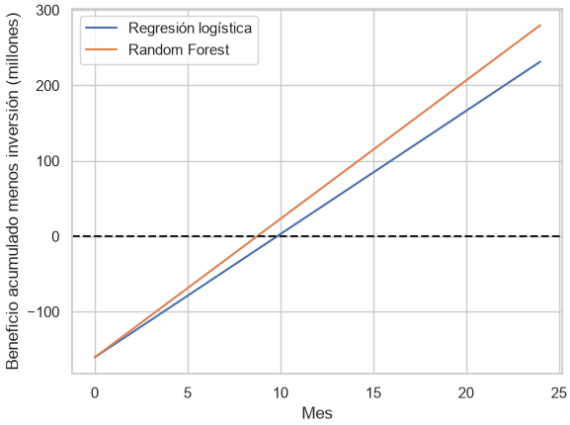


Figura 3. Beneficio acumulado menos inversión, con umbral 0,5.

Sensibilidad. El resultado depende sobre todo del éxito real de la campaña (Tabla 2).

Escenario	Millones al mes	Meses para recuperar	ROI a 12 meses
Base	20,0	8,0	49 %
Éxito de la campaña 15 %	3,6	44,9	-73 %
Éxito de la campaña 45 %	36,3	4,4	172 %
Ingreso 500.000	10,6	15,1	-21 %
Ingreso 900.000	29,3	5,5	119 %
Contacto 10.000	29,9	5,4	124 %
Contacto 80.000	10,1	15,9	-24 %

Tabla 2. Random Forest con umbral 0,6, cambiando un supuesto a la vez.

5. Recomendación

Recomendamos usar Random Forest con umbral 0,6 para elegir a quién contactar, con estas condiciones:

- **Piloto primero.** Medir cuántos clientes contactados se quedan. El 30 % de éxito es el supuesto que más mueve la ganancia: con 15 % la inversión tardaría casi 4 años en recuperarse.
- **Oferta según la razón.** Usar las razones de cada cliente (SHAP): a los inactivos, algo que los haga usar el banco; a los que tienen un solo producto, un segundo producto.
- **Ajustar el umbral.** Si contactar resulta barato o el banco prefiere no perder clientes, bajar el umbral o usar la logística, que detecta más abandonos.
- **Reentrenar.** El modelo se entrenó con clientes europeos y 20,4 % de abandono. Hay que reentrenarlo con clientes del banco.

Limitaciones. Los costos salen de fuentes públicas y no de cotizaciones, retener a un cliente se valoró como un año de ingreso y no se incluyeron costos después del lanzamiento.

Declaración de uso de IA generativa

Se usó Claude Opus 5.5 (Anthropic), a través de Claude Code, para organizar el notebook y hacer correcciones de estilos en las celdas de texto. Porcentaje de ayuda: 20%. Los prompts están en la sección 7 del notebook.

Referencias

Dólar Colombia. (2026). Precio TRM del dólar 6 de noviembre de 2026. https://www.dolar-colombia.com/2026-11-06

Elempleo. (2026). Ofertas de trabajo de data engineer. https://www.elempleo.com/co/ofertas-empleo/trabajo-data-engineer

Glassdoor. (2026). Salario: científico de datos en Bogotá. https://www.glassdoor.com/Salaries/bogot%C3%A1-bogota-cient%C3%ADfico-de-datos-salary-SRCH_IL.0,13_IC4309640_KO14,33.htm

Indeed. (2026). Sueldo de data scientist en Colombia. https://co.indeed.com/career/data-scientist/salaries

Noticias RCN. (2026). Cuota de manejo 2026: ¿cuáles son los bancos más caros y cuáles no cobran nada? https://www.noticiasrcn.com/economia/cuota-de-manejo-bancos-mas-caros-y-gratuitos-1045068

Provost, F., y Fawcett, T. (2013). Data science for business. O'Reilly Media.

Talkyria. (2026). Cuánto cuesta un call center para ecommerce en Colombia en 2026. https://talkyria.com/blog/cuanto-cuesta-call-center-ecommerce-colombia

UNIR. (s. f.). Cuánto gana un ingeniero en inteligencia artificial. https://colombia.unir.net/actualidad-unir/cuanto-gana-ingeniero-inteligencia-artificial/

Universidad de los Andes. (s. f.). Prácticas de machine learning. https://datascience-uniandes.github.io/PracticasMachineLearning/

Universidad de los Andes. (2026). Taller 2. MINE-4101 Ciencia de Datos Aplicada.